REPUBLIQUE DU SENEGAL



Un Peuple – Un But – Une Foi

MINISTERE DE L'ENSEIGNEMENT SUPÉRIEUR DE LA RECHERCHE ET DE L'INNOVATION
UNIVERSITÉ IBA DER THIAM DE THIÈS



U.F.R DES SCIENCES ET TECHNOLOGIES
DEPARTEMENT INFORMATIQUE

Master 2 – Génie - Logiciel

THÈME :

Conception d'un système d'apprentissage fédéré sécurisé basé sur le chiffrement homomorphe pour la protection des données médicales.

RAPPORT DE MÉMOIRE

Présentée par :

Fatou FALL

Sous la direction de : M.

2025-2026

TABLE DES MATIÈRES

Liste des sigles et abréviations..... 4
Résumé..... 4
Abstract..... 4
Liste des figures..... 4
Liste des tableaux..... 4
INTRODUCTION GÉNÉRALE..... 4
Contexte et motivation du projet..... 4
Problématique..... 5
Objectifs du projet..... 6
Contribution originale..... 7
Organisation du document..... 8
Chapitre 1 : État de l'art..... 8
1.1 Apprentissage automatique et données médicales..... 8
1.2 L'apprentissage fédéré (Federated Learning)..... 9
1.3 Vulnérabilités et menaces en apprentissage fédéré..... 11
1.4 Techniques de préservation de la vie privée..... 12
1.5 Le chiffrement homomorphe - état de l'art..... 13
1.6 Travaux existants sur l'apprentissage fédéré sécurisé en santé..... 14
1.7 Synthèse et positionnement de la recherche..... 16
Chapitre 2 : Analyse des besoins et spécifications du système..... 17
2.1 Contexte d'utilisation..... 17
2.2 Exigences fonctionnelles..... 18
2.3 Exigences non fonctionnelles..... 19
2.4 Contraintes techniques et réglementaires..... 20
2.5 Cas d'utilisation..... 21
Chapitre 3 : Conception d'un modèle théorique d'architecture sécurisée..22
3.1 Modèle de menace et hypothèses..... 22
3.2 Architecture globale proposée..... 22
3.3 Choix et justification du schéma de chiffrement homomorphe..... 22
3.4 Protocole d'apprentissage fédéré sécurisé..... 22
3.5 Analyse théorique de sécurité..... 22
Chapitre 4 : Implémentation du prototype..... 23
4.1 Implémentation expérimentale en Python (PyTorch) 23
4.2 Intégration d'une bibliothèque de chiffrement homomorphe..... 23

4.3 Implémentation du protocole fédéré.....23
4.4 Interface et communication..... 23
4.5 Gestion des paramètres cryptographiques..... 23
Chapitre 5 : Expérimentations et résultats.....23
5.1 Présentation des jeux de données 23
5.2 Protocole expérimental..... 23
5.3 Métriques d'évaluation.....23
5.4 Résultats de performance des modèles..... 23
5.5 Impact du chiffrement sur les temps de calcul..... 23
5.6 Analyse comparative : FL classique et FL chiffré (CKKS, BFV, Paillier) 23
Chapitre 6 : Discussion et perspectives.....24
6.1 Synthèse des contributions..... 24
6.2 Limitations de l'approche.....24
6.3 Implications pratiques.....24
6.4 Travaux futurs.....24
Conclusion et perspectives..... 24
Synthèse des travaux réalisés.....24
Apports du projet.....24
Perspectives d'amélioration..... 24
Références bibliographiques..... 24
Annexes..... 24
Annexe A : Détails des paramètres expérimentaux.....24
Annexe B : Extraits de code..... 24
Annexe C : Glossaire des termes techniques.....24
Annexe D : Publications et communications.....24

Liste des sigles et abréviations

Résumé

Abstract

Liste des figures

Liste des tableaux

INTRODUCTION GÉNÉRALE

Contexte et motivation du projet

Le secteur de la santé génère aujourd'hui des volumes de données considérables. Dossiers médicaux électroniques, résultats d'analyses biologiques, images radiologiques, données de suivi de patients chroniques tout cela constitue une matière première d'une richesse exceptionnelle pour entraîner des modèles d'intelligence artificielle capables d'assister les cliniciens dans leurs diagnostics. Plusieurs études ont démontré que des algorithmes d'apprentissage automatique correctement entraînés peuvent rivaliser avec des médecins spécialistes sur des tâches précises comme la détection du cancer, la prédiction du diabète de type 2 ou l'identification précoce de maladies cardiovasculaires.

Cependant, cette promesse se heurte à un obstacle fondamental : les données médicales sont parmi les plus sensibles qui soient. Elles touchent à l'intimité des personnes, engagent la responsabilité des établissements de santé, et font l'objet de réglementations strictes dans la plupart des pays. Partager ces données entre hôpitaux, même à des fins de recherche, soulève des questions éthiques, juridiques et sécuritaires qui ne peuvent être ignorées. En pratique, cela signifie que chaque établissement conserve ses données de son côté, ce qui empêche la construction de modèles d'IA robustes nécessitant des volumes importants et diversifiés de données d'entraînement.

Cette tension entre l'utilité de la donnée médicale et la nécessité de la protéger est au cœur de la problématique que ce mémoire cherche à traiter. En Afrique de l'Ouest, cette tension est encore plus marquée. Les systèmes de santé y font face à des défis spécifiques : infrastructures parfois limitées, faible connectivité dans certaines zones, et pathologies locales diabète, drépanocytose, paludisme dont la prise en charge bénéficierait énormément d'outils d'aide au diagnostic entraînés sur des données locales. Or ces données existent, dispersées dans les hôpitaux régionaux, mais elles ne sont ni partagées ni exploitées à leur plein potentiel. Ces hôpitaux disposent souvent de machines modestes, sans carte graphique, et d’une connexion internet instable.

Toute solution de protection des données doit donc rester légère pour être utilisable sur le terrain.

Problématique

Face à ce constat, une question centrale se pose : comment permettre à plusieurs établissements de santé de collaborer pour entraîner un modèle d'intelligence artificielle performant, sans qu'aucun d'eux n'ait à exposer ses données patients ?

L'apprentissage fédéré, ou Federated Learning, apporte une première réponse à cette question. Ce paradigme d'apprentissage distribué permet à plusieurs institutions de s'entraîner localement sur leurs propres données, puis d'envoyer uniquement les paramètres de leurs modèles et non les données brutes à un serveur central chargé de les agréger. Les données ne quittent jamais l'établissement qui les détient. C'est une avancée réelle.

Mais cette approche n'est pas sans failles. Des travaux récents ont montré qu'un adversaire capable d'intercepter les gradients échangés entre les nœuds peut, dans certaines conditions, reconstituer une partie des données originales. Cette attaque, connue sous le nom de Deep Leakage from Gradients, remet en question la confidentialité supposée du Federated Learning classique. D'autres types d'attaques inférence d'appartenance, empoisonnement de modèle viennent compléter ce tableau de menaces.

C'est ici qu'intervient le chiffrement homomorphe. Contrairement au chiffrement classique qui nécessite de déchiffrer les données pour effectuer des calculs dessus, le chiffrement homomorphe permet d'opérer directement sur des données chiffrées et d'obtenir un résultat chiffré équivalent à celui que l'on aurait obtenu sur les données en clair. Appliqué à l'apprentissage fédéré, il permet de chiffrer les gradients avant leur envoi, de sorte que le serveur agrège des valeurs qu'il ne peut pas lire et que tout adversaire interceptant les communications ne voit que du bruit cryptographique.

La combinaison de ces deux approches Federated Learning et chiffrement homomorphe constitue donc une piste sérieuse pour construire des systèmes

d'apprentissage collaboratif réellement sécurisés. Mais cette combinaison a un coût : le chiffrement homomorphe est computationnellement coûteux, ce qui pose des défis réels de déploiement, en particulier dans des environnements à ressources limitées comme ceux que l'on trouve dans les établissements de santé d'Afrique de l'Ouest.

La problématique de ce mémoire se formule donc ainsi :

Comment concevoir et implémenter un système d'apprentissage fédéré sécurisé par chiffrement homomorphe, adapté à la protection des données médicales, tout en gardant des performances acceptables sur des machines à ressources limitées ?

De cette question principale découle une question secondaire : parmi les schémas CKKS, BFV et Paillier, lequel offre le meilleur compromis entre sécurité, précision du modèle et coût de calcul dans ce système ?

Objectifs du projet

Ce travail poursuit un objectif général et plusieurs objectifs spécifiques.

L'objectif général est de concevoir, implémenter et évaluer un prototype de système d'apprentissage fédéré sécurisé par chiffrement homomorphe, appliqué à la prédiction de maladies à partir de données médicales.

De manière plus spécifique, ce mémoire vise à :

premièrement, réaliser un état de l'art sur les approches existantes combinant apprentissage fédéré et techniques de préservation de la vie privée, afin de positionner clairement la contribution de ce travail par rapport à l'état de l'art ;

deuxièmement, concevoir une architecture théorique d'un système FL+HE en définissant le modèle de menace, les hypothèses de sécurité, et le protocole d'agrégation sécurisée ;

troisièmement, implémenter un prototype fonctionnel en Python qui simule plusieurs hôpitaux. Ce prototype intègre trois schémas de chiffrement homomorphe : CKKS et

BFV avec la bibliothèque TenSEAL, et Paillier avec la bibliothèque python-paillier (phe). Le module de chiffrement est interchangeable, ce qui permet de comparer les trois schémas dans les mêmes conditions ;

quatrièmement, évaluer ce prototype sur des jeux de données médicaux publics : la prédiction du diabète (Pima Indians Diabetes), des maladies cardiaques (UCI Heart Disease) et de la drépanocytose à partir d'images de sang collectées en Ouganda. Un quatrième jeu, sur la maladie rénale chronique, permet une comparaison indicative avec les résultats de Hegde et al. (2025), qui étudient la même maladie. L'évaluation mesure la précision du modèle et le coût du chiffrement : temps de calcul, taille des messages échangés et mémoire vive utilisée ;

et cinquièmement, comparer quatre configurations : l'apprentissage fédéré sans chiffrement, puis avec CKKS, avec BFV et avec Paillier. Cette comparaison se fait au même niveau de sécurité (128 bits) et permet d'analyser le compromis entre sécurité, précision et coût de calcul.

Contribution originale

Ce travail se distingue des recherches existantes sur deux points.

D'abord, il compare directement trois schémas de chiffrement homomorphe, CKKS, BFV et Paillier, dans un même cadre expérimental médical. Les travaux étudiés n'utilisent en général qu'un seul schéma : Hegde et al. (2025, p. 26023) utilisent CKKS, et Shahid et al. (2026, p. 1) utilisent Paillier. À notre connaissance, peu de travaux comparent ces trois schémas avec les mêmes données, le même modèle et le même niveau de sécurité. Cette comparaison peut guider les choix techniques de futurs projets.

Ensuite, ce travail tient compte des contraintes des hôpitaux d'Afrique de l'Ouest. Fabila et al. (2024, pp. 7-8) ont montré que l'apprentissage fédéré fonctionne sur des machines modestes en Afrique, mais sans chiffrer les poids échangés. Ce mémoire ajoute cette couche de chiffrement et mesure son coût sur une machine ordinaire sans carte graphique.

Il faut cependant préciser un point. La plupart des jeux de données utilisés sont publics et ne viennent pas d'Afrique de l'Ouest. Le contexte ouest-africain est donc pris en compte surtout à travers les contraintes techniques, comme la puissance de calcul et la qualité du réseau. Une partie des expériences utilise tout de même des données africaines : des images de sang de patients drépanocytaires collectées en Ouganda. L'utilisation de données ouest-africaines réelles reste une perspective de ce travail.

Organisation du document

Ce rapport est structuré en six chapitres. Le premier présente un état de l'art couvrant l'apprentissage automatique en santé, le Federated Learning, ses vulnérabilités, et les techniques de préservation de la vie privée. Le deuxième chapitre analyse les besoins du système et définit les exigences fonctionnelles et non fonctionnelles. Le troisième propose un modèle théorique d'architecture sécurisée. Le quatrième décrit l'implémentation du prototype. Le cinquième présente les expérimentations et les résultats obtenus. Le sixième et dernier chapitre discute les contributions, les limites de l'approche et les perspectives de travaux futurs.

Chapitre 1 : État de l'art

Ce chapitre présente les connaissances nécessaires pour comprendre notre travail. Il s'appuie sur quatre articles principaux, choisis parce qu'ils traitent directement du sujet : Hegde et al. (2025), Shahid et al. (2026), Fabila et al. (2024) et Li et Li (2025). D'autres travaux de référence complètent cette base.

1.1 Apprentissage automatique et données médicales

L'intelligence artificielle occupe aujourd'hui une place croissante dans le domaine de la santé. Les avancées récentes en apprentissage automatique ont ouvert des perspectives considérables pour l'aide au diagnostic, la prédiction de risques cliniques, la personnalisation des traitements et la surveillance épidémiologique. Des modèles entraînés sur des milliers de cas ont montré des capacités diagnostiques comparables à celles de médecins expérimentés dans des domaines aussi variés que la dermatologie, la radiologie ou la cardiologie.

Ces résultats reposent sur un principe simple mais exigeant : plus un modèle dispose de données diversifiées et représentatives lors de son entraînement, meilleure sera sa capacité de généralisation. C'est là que réside la principale difficulté dans le domaine médical. Les données cliniques sont par nature fragmentées. Elles sont réparties entre des centaines d'établissements qui, pour des raisons légitimes de confidentialité, de réglementation et de souveraineté institutionnelle, ne peuvent pas les partager librement. Un hôpital à Thiès ne transmettra pas ses dossiers patients à un établissement de Dakar, même si cette collaboration pourrait améliorer la qualité d'un modèle de détection du diabète ou de la drépanocytose.

Cette réalité crée ce que les chercheurs appellent des silos de données. Chaque établissement dispose de données insuffisantes pour entraîner un modèle robuste seul, mais l'agrégation centralisée de toutes ces données pose des problèmes éthiques et sécuritaires que ni les institutions ni les patients n'accepteraient facilement. Le cadre réglementaire renforce cette contrainte. Des textes comme le Règlement Général sur la Protection des Données en Europe, ou les dispositions équivalentes qui émergent

progressivement dans les législations africaines, encadrent strictement la collecte, le stockage et le transfert des données de santé à caractère personnel.

Face à ce contexte, l'apprentissage automatique distribué s'est imposé comme une piste de recherche majeure. L'idée centrale est de déplacer le calcul vers les données plutôt que de déplacer les données vers le calcul. Plusieurs paradigmes ont émergé dans cette direction, dont le plus abouti à ce jour est l'apprentissage fédéré.

1.2 L'apprentissage fédéré (Federated Learning)

L'apprentissage fédéré, proposé par McMahan et al. (2017) chez Google pour améliorer le clavier des téléphones mobiles, est un paradigme d'apprentissage distribué qui permet à plusieurs participants de collaborer à l'entraînement d'un modèle partagé sans échanger leurs données brutes. Chaque participant entraîne localement un modèle sur ses propres données, puis transmet uniquement les paramètres mis à jour généralement les gradients ou les poids du modèle à un serveur central. Ce serveur agrège les contributions de tous les participants, typiquement par une moyenne pondérée connue sous le nom de FedAvg, et redistribue le modèle global mis à jour à chaque nœud pour le tour d'entraînement suivant.

Ce mécanisme présente plusieurs propriétés intéressantes pour les applications médicales. D'abord, les données patients ne quittent jamais l'établissement qui les détient. Ensuite, le modèle global bénéficie de la diversité des données de tous les participants, ce qui améliore sa robustesse et sa généralisation. Enfin, l'architecture est naturellement adaptée aux contextes distribués où la connectivité n'est pas permanente, puisque les nœuds n'ont besoin de communiquer qu'à des intervalles définis entre les rounds d'entraînement.

On distingue généralement deux grandes configurations d'apprentissage fédéré. Dans le FL horizontal, tous les participants partagent le même espace de features mais ont des instances différentes, c'est le cas typique de plusieurs hôpitaux qui ont tous des dossiers patients avec les mêmes variables cliniques mais des patients différents. Dans le FL vertical, les participants partagent les mêmes instances mais des features

différentes par exemple un hôpital qui détient les données biologiques et une assurance qui détient les données socio-économiques des mêmes patients. Dans le cadre de ce mémoire, c'est le FL horizontal qui nous intéresse, car il correspond à la configuration la plus naturelle pour la collaboration inter-hospitalière.

Malgré ses avantages, l'apprentissage fédéré souffre de plusieurs limitations techniques. L'hétérogénéité des données entre participants que les chercheurs désignent par le terme non-IID, pour non Independent and Identically Distributed peut dégrader significativement la convergence du modèle global. Si un hôpital a majoritairement des patients diabétiques et un autre principalement des patients cardiaques, l'agrégation de leurs gradients produit un modèle global moins précis que ce que chacun obtiendrait localement. Des algorithmes comme FedProx ou SCAFFOLD ont été proposés pour atténuer ce problème, mais la question reste ouverte.

L'autre limitation majeure, et c'est celle qui nous concerne le plus directement dans ce mémoire, est d'ordre sécuritaire. Le FL classique offre une protection de la vie privée qui est, en réalité, plus apparente que réelle.

1.3 Vulnérabilités et menaces en apprentissage fédéré

L'idée que le Federated Learning protège naturellement la vie privée parce que les données brutes ne sont pas partagées est une simplification trompeuse. Des travaux de recherche successifs ont démontré que les paramètres échangés pendant l'entraînement, gradients et poids du modèle peuvent révéler des informations sensibles sur les données d'entraînement locales.

La menace la plus étudiée est l'attaque par inversion de gradients, formalisée par Zhu et al. (2019) dans leur travail fondateur sur le Deep Leakage from Gradients. Ces auteurs ont montré qu'en connaissant l'architecture du modèle et en observant les gradients transmis par un nœud, un adversaire peut résoudre un problème d'optimisation inverse pour reconstruire les données d'entraînement correspondantes avec une précision surprenante. Sur des images médicales, cette attaque peut

permettre de retrouver le contenu d'une radiographie. Sur des données tabulaires cliniques, elle peut révéler des valeurs de glycémie, de pression artérielle ou d'autres mesures biologiques.

La deuxième famille de menaces concerne les attaques par inférence d'appartenance. L'objectif ici n'est pas de reconstruire les données mais de déterminer si un enregistrement particulier a été utilisé pour entraîner le modèle. Dans un contexte médical, savoir qu'un individu spécifique figure dans la base d'entraînement d'un modèle de prédiction du cancer constitue déjà une violation grave de sa vie privée.

Il existe également des attaques par empoisonnement, où un participant malveillant manipule délibérément les gradients qu'il envoie au serveur, soit pour dégrader les performances globales du modèle, c'est ce qu'on appelle l'empoisonnement de modèle, soit pour introduire un comportement spécifique non désiré, ce que l'on désigne sous le terme d'attaque par porte dérobée ou backdoor attack. Ces menaces concernent davantage l'intégrité du modèle que la confidentialité des données, mais elles n'en sont pas moins critiques dans un contexte médical où un modèle de diagnostic manipulé pourrait produire des résultats erronés.

Enfin, il convient de mentionner la menace que représente un serveur central honnête-mais-curieux, c'est-à-dire un serveur qui respecte le protocole fédéré mais qui enregistre et analyse les gradients reçus pour tenter d'en extraire des informations sur les données des participants. Dans un déploiement réel, cette menace est particulièrement réaliste puisque le serveur est souvent géré par un tiers en qui les participants n'ont qu'une confiance partielle.

Ce panorama de menaces justifie pleinement la recherche de mécanismes de protection supplémentaires au-delà de la simple séparation des données que propose le FL classique.

1.4 Techniques de préservation de la vie privée

Plusieurs approches ont été proposées pour renforcer la confidentialité dans les systèmes d'apprentissage fédéré. Les trois principales sont la confidentialité différentielle, le calcul multipartite sécurisé, et le chiffrement homomorphe.

La confidentialité différentielle, ou Differential Privacy, consiste à ajouter un bruit mathématiquement calibré aux gradients avant leur transmission. Ce bruit est suffisamment faible pour ne pas trop dégrader la qualité du modèle, mais suffisamment fort pour empêcher un adversaire de reconstituer les données individuelles à partir des gradients bruités. Cette technique offre des garanties formelles sur la quantité d'information qui peut être extraite sur un individu donné, exprimées par un paramètre epsilon. Plus epsilon est faible, plus la protection est forte, mais plus la précision du modèle en souffre. Ce compromis entre utilité et vie privée est l'une des limites fondamentales de la DP.

Le calcul multipartite sécurisé, ou Secure Multi-Party Computation, est un ensemble de protocoles cryptographiques permettant à plusieurs parties de calculer conjointement une fonction sur leurs entrées respectives sans qu'aucune ne révèle ses entrées aux autres. Appliqué au FL, il permet au serveur d'agréger les gradients de tous les participants sans voir les contributions individuelles. Cette approche offre de solides garanties de sécurité, mais elle implique de nombreux échanges de messages entre les participants, ce qui génère un overhead de communication important, particulièrement problématique dans des contextes à faible bande passante.

Le chiffrement homomorphe représente une troisième voie, plus directe. Contrairement à la DP qui dégrade les données et au SMPC qui requiert une interaction intensive entre participants, le chiffrement homomorphe permet à chaque participant de chiffrer ses gradients de manière autonome avant de les envoyer, et au serveur d'effectuer l'agrégation directement sur les données chiffrées. Le résultat déchiffré est identique à ce qu'on aurait obtenu en travaillant sur les données en clair. C'est cette propriété remarquable que nous allons examiner en détail dans la section suivante.

1.5 Le chiffrement homomorphe - état de l'art

Le chiffrement homomorphe trouve ses racines dans les travaux théoriques de Rivest, Adleman et Dertouzos en 1978, qui avaient posé la question de savoir s'il était possible d'effectuer des calculs sur des données chiffrées. Pendant plus de trente ans, cette question est restée sans réponse satisfaisante. C'est Craig Gentry qui, en 2009, a proposé le premier schéma de chiffrement pleinement homomorphe, c'est-à-dire supportant à la fois l'addition et la multiplication un nombre arbitraire de fois sur des données chiffrées. Cette avancée théorique majeure a ouvert la voie à une génération de schémas pratiques.

Aujourd'hui, les schémas les plus utilisés en apprentissage automatique sont au nombre de trois principaux. Le schéma de Paillier, proposé en 1999, est un schéma partiellement homomorphe qui supporte uniquement l'addition de valeurs chiffrées et la multiplication par un scalaire en clair. Il est simple et très utilisé pour l’agrégation en apprentissage fédéré. Il présente cependant deux limites. Il travaille sur des entiers, donc les poids du modèle doivent être convertis avant le chiffrement. Dans sa version de base, il chiffre aussi une seule valeur à la fois, ce qui devient lent quand le modèle contient des milliers de poids. Des techniques permettent de regrouper plusieurs valeurs dans un même message Paillier, mais elles demandent de réduire la précision des poids (Zhang et al., 2020, p. 493).

Le schéma BFV, proposé par Brakerski, Fan et Vercauteren, supporte les opérations sur des entiers, avec à la fois l'addition et la multiplication homomorphes. Il offre une efficacité computationnelle supérieure à Paillier pour les opérations entières, mais nécessite une conversion des données en virgule flottante vers des représentations entières, ce qui introduit une complexité supplémentaire et une perte de précision potentielle.

Le schéma CKKS, proposé par Cheon, Kim, Kim et Song en 2017, est celui qui a transformé l'applicabilité du chiffrement homomorphe à l'apprentissage automatique. Sa particularité est de supporter directement les calculs approximatifs sur des nombres à virgule flottante, en acceptant une légère erreur d'arrondi contrôlée. Cette propriété

le rend particulièrement bien adapté aux opérations d'agrégation de gradients en FL, où les valeurs sont des flottants et où une légère imprécision est acceptable. CKKS peut aussi regrouper des milliers de valeurs dans un seul message chiffré. Pour ces raisons, il est souvent présenté comme un bon candidat pour l'apprentissage profond. Li et Li (2025, p. 4) le classent comme le deuxième schéma le plus utilisé en apprentissage fédéré, après Paillier. Ce mémoire vérifie par l'expérience s'il est réellement le plus adapté.

Le principal obstacle au déploiement pratique du chiffrement homomorphe reste son coût computationnel. Les opérations sur données chiffrées sont significativement plus lentes que leurs équivalents sur données en clair le ralentissement dépend des opérations effectuées et des paramètres de sécurité choisis. Des approches récentes proposent le chiffrement sélectif, c'est-à-dire ne chiffrer que les composantes les plus sensibles des gradients plutôt que l'ensemble, pour réduire ce coût tout en gardant une protection suffisante. Jin et al. (2023, p. 1) réduisent ainsi le coût du chiffrement d'environ 10 fois pour le modèle ResNet-50. Korkmaz et Rao (2025, p. 1) obtiennent un système jusqu'à 90 % plus rapide qu'un chiffrement complet, sur des images médicales.

1.6 Travaux existants sur l'apprentissage fédéré sécurisé en santé

La combinaison de l'apprentissage fédéré et du chiffrement homomorphe pour la protection des données médicales a fait l'objet d'une activité de recherche soutenue ces dernières années. Quatre travaux constituent le socle de référence sur lequel ce mémoire s'appuie directement.

Hegde et al. (2025) ont mis en place un système d'apprentissage fédéré chiffré avec CKKS, à l'aide de la bibliothèque TenSEAL, pour prédire le stade de la maladie rénale chronique. Leur système compte un serveur et quatre hôpitaux simulés (p. 26019). Ils ont d'abord attaqué le FL sans chiffrement avec trois attaques : l'inversion de modèle, l'inférence d'appartenance et la fuite de gradients. Les trois attaques ont réussi (p. 26023). Avec le chiffrement, ces attaques sont devenues « impossibles en pratique sur le plan du calcul » (p. 26024). Le modèle chiffré atteint 98,6 %

d'accuracy au dixième round, contre 98,7 % sans chiffrement (p. 26023). Le coût reste modéré : un round complet passe de 5,93 s à 7,45 s (p. 26023), mais la taille moyenne d'un échange passe de 0,395 Mo à 7,825 Mo (p. 26024, tableau V).

Ce travail présente cependant trois limites. D'abord, il ne compare pas CKKS avec d'autres schémas. Ensuite, le jeu de données ne contient que 399 vrais patients, collectés dans un hôpital de Bangalore, en Inde (p. 26020). Les auteurs l'ont complété avec l'outil Gretel.ai pour obtenir 5 000 exemples synthétiques (pp. 26020-26021). Le score de 98,6 % doit donc être lu avec prudence. Enfin, dans leur système, c'est le serveur qui déchiffre le résultat de l'agrégation (p. 26020). Le serveur détient donc la clé secrète, ce que notre conception évite.

Shahid et al. (2026) proposent Health-FedNet, un système qui combine la confidentialité différentielle, le chiffrement de Paillier et une pondération adaptative des hôpitaux. Ils l'appliquent à la prédiction du diabète et de l'hypertension sur la base MIMIC-III (p. 1), répartie entre cinq établissements simulés (p. 8, tableau 5). Leur modèle atteint 92 % d'accuracy et un AUC-ROC de 0,94, avec une baisse de 41,6 % du coût de communication (p. 1). La clé de Paillier mesure 2048 bits (p. 13, tableau 7).

Ce travail présente cependant plusieurs limites. Il utilise seulement Paillier. Les auteurs expliquent eux-mêmes qu'ils n'ont pas comparé leur système à CKKS et qu'ils gardent cette comparaison pour des travaux futurs (p. 18). Il combine aussi la confidentialité différentielle et le chiffrement, ce qui rend difficile de mesurer l'effet du chiffrement seul. Certains résultats surprennent : le modèle centralisé (82 %) fait moins bien que le modèle fédéré de base (85 %) (p. 12), alors qu'on attend en général l'inverse. Enfin, l'étude utilise uniquement des données américaines, sans tenir compte des environnements à ressources limitées.

Li et Li (2025) ont publié une revue systématique, encore en prépublication, sur le chiffrement homomorphe en apprentissage fédéré. Ils retiennent 50 études publiées entre 2021 et 2024 (p. 2). Paillier est le schéma le plus utilisé : il apparaît dans 13 études, soit 36 % des 36 études présentées dans leur figure 2. CKKS arrive en

deuxième position avec 28 %, alors que BFV ne représente que 3 % (p. 4, fig. 2). Les auteurs identifient le coût de calcul comme le défi principal, et le coût de communication comme le deuxième (p. 5). Ils signalent aussi un manque de tests sur des données réelles, en particulier dans le domaine de la santé (p. 5). Ce mémoire contribue à réduire ce manque.

Fabila et al. (2024) ont étudié l'apprentissage fédéré dans des environnements à faibles ressources en Afrique. Ils ont entraîné un classificateur d'images échographiques fœtales avec des données de cinq pays africains (Algérie, Égypte, Ghana, Malawi et Ouganda) et d'Espagne (p. 1). Un seul nœud d'entraînement disposait d'une carte graphique. Les autres utilisaient seulement leur processeur, et l'un d'eux était un Raspberry Pi 5 (p. 5, tableau 2). Le modèle centralisé reste plus stable, mais le modèle fédéré atteint une précision comparable après peu de rounds (p. 7). Le Raspberry Pi a pu participer à l'entraînement, même s'il était le nœud le plus lent (pp. 7-8). Ce résultat montre que l'apprentissage fédéré est faisable dans le contexte africain. Cependant, la sécurité repose seulement sur le protocole SSL (p. 4). SSL protège les messages pendant leur transport, mais le serveur reçoit les poids en clair. Un serveur curieux pourrait donc les analyser. L'absence de chiffrement homomorphe dans ce travail constitue le manque que ce mémoire cherche à combler.

D'autres travaux ont déjà comparé plusieurs schémas, mais dans des cadres différents du nôtre. Jorge et al. (2025) comparent six schémas, dont Paillier, BFV et CKKS, au même niveau de sécurité de 128 bits (p. 6). Leur étude n'utilise pas l'apprentissage fédéré : elle chiffre seulement les 100 premières valeurs de la colonne « âge » d'un jeu de données de santé synthétique (p. 5). Sur ces 100 valeurs, le chiffrement prend environ 32 s avec Paillier, contre 1,7 s avec BFV et 3,3 s avec CKKS (p. 8, tableau 6). Les auteurs concluent qu'aucun schéma n'est le meilleur dans tous les cas (p. 1). Jiang et al. (2021) comparent Paillier, BFV et CKKS dans un cadre fédéré, mais sur des données non médicales (p. 2). Ils montrent que le regroupement de plusieurs valeurs dans un même message réduit fortement le coût des trois schémas (p. 3, tableau 2). Zhang et al. (2020) montrent que, sans regroupement, Paillier occupe plus de 80 % du temps d'entraînement et multiplie le volume des échanges par plus de 150 (p. 493).

Enfin, les travaux récents en santé utilisent presque toujours un seul schéma, le plus souvent CKKS. Walskaar et al. (2023) l'appliquent à des radios pulmonaires et obtiennent, avec trois clients, 96,4 % d'accuracy contre 96,8 % sans chiffrement (p. 33, tableau 6). Al-Janabi et al. (2025) l'appliquent à des électrocardiogrammes et obtiennent 88,12 % d'accuracy, avec une hausse du temps de calcul de seulement 1,08 % à 1,43 % selon le nombre de clients (p. 3094). Ces résultats confirment l'intérêt de comparer les trois schémas dans un même cadre fédéré médical.

Le tableau suivant synthétise les caractéristiques de ces quatre travaux et positionne le présent mémoire par rapport à l'état de l'art.

Tableau de synthèse :

Travail	Année	Schéma HE	Dataset	Contexte	Comparaison schémas	Ressources contraintes
Hegde et al.	2025	CKKS (TenSEAL)	CKD Inde (399 patients + données synthétiques)	Asie	Non	Non
Shahid et al. (Health-FedNet)	2026	Paillier + DP	MIMIC-III - USA	Amérique	Non	Non
Fabila et al.	2024	Aucun(SSL seulement)	Images périnatales, 5 pays africains + Espagne	Afrique	Non	Oui
Li & Li	2025	Revue comparative	50 études (2021-2024), prépublication	Global	Oui(revue)	Non
Jorge et al.	2025	6 schémas dont Paillier, BFV, CKKS (sans FL)	Santé, synthétique (100 valeurs)	Portugal	Oui	Non
Jiang et al. (FLASHE)	2021	Paillier, BFV, CKKS +	Non médical	Global	Oui	Non

		FLASHE				
Walskaar et al.	2023	xMK-CKKS (multi-clés)	Radios pulmonaires COVID-19	Cloud (AWS)	Non	Non
Al-Janabi et al.	2025	CKKS	ECG (MIT-BIH)	Irak	Non	Non
Ce mémoire	2026	CKKS + BFV + Paillier	Diabète (Pima), Cardio (UCI, 4 centres), Drépanocytose (images, Ouganda), CKD (Inde)	Contraintes de l'Afrique de l'Ouest	Oui	Oui

1.7 Synthèse et positionnement de la recherche

L'analyse de la littérature permet de dresser un constat clair. Les travaux existants sur FL+HE en santé sont techniquement solides et leurs résultats sont encourageants. Cependant, ils présentent collectivement plusieurs lacunes qui définissent l'espace de contribution de ce mémoire.

Premièrement, à notre connaissance, très peu de travaux étudient des systèmes d'apprentissage fédéré chiffrés dans le contexte des hôpitaux d'Afrique de l'Ouest. Fabila et al. (2024) testent des machines modestes en Afrique, mais sans chiffrement homomorphe. Hegde et al. (2025) utilisent un ordinateur portable sans carte graphique dédiée (p. 26023), mais avec un seul schéma et sans prendre en compte les contraintes du terrain africain.

Deuxièmement, les comparaisons entre CKKS, BFV et Paillier existent, mais elles sont faites soit sans apprentissage fédéré (Jorge et al., 2025), soit sans données médicales (Jiang et al., 2021). À notre connaissance, aucune étude ne compare ces trois schémas dans un même système fédéré médical, au même niveau de sécurité et sur une machine à ressources limitées.

Troisièmement, les maladies fréquentes en Afrique, comme la drépanocytose, sont rarement étudiées dans les travaux qui combinent apprentissage fédéré et chiffrement homomorphe. Ce mémoire inclut une expérience sur des images de sang de patients drépanocytaires collectées en Ouganda, et teste le système dans des conditions techniques proches de celles de l'Afrique de l'Ouest.

Ce mémoire se positionne donc à l'intersection de ces trois lacunes. Il ne cherche pas à proposer un nouveau schéma cryptographique, ce serait hors de portée d'un travail de Master 2, mais à adapter, implémenter, évaluer et comparer les approches existantes dans un contexte encore peu exploré, en produisant des résultats concrets et directement utiles pour les acteurs de la santé numérique en Afrique de l'Ouest.

Chapitre 2 : Analyse des besoins et spécifications du système

2.1 Contexte d'utilisation

Pour concevoir un système cohérent, il faut d'abord définir précisément le cadre dans lequel il sera utilisé. Dans ce mémoire, le système envisagé s'inscrit dans un scénario de collaboration inter-hospitalière pour l'entraînement d'un modèle d'aide au diagnostic. Plus concrètement, on considère plusieurs établissements de santé au moins trois, qui souhaitent collaborer pour améliorer la précision d'un modèle de prédiction de maladies, sans qu'aucun d'eux ne cède ses données à un tiers.

Chaque établissement dispose de son propre système informatique, de ses propres dossiers patients et d'une capacité de calcul locale modeste. Les établissements sont reliés par un réseau dont la fiabilité et la bande passante ne peuvent pas être garanties en permanence, une contrainte particulièrement réaliste dans le contexte ouest-africain

où la connectivité reste inégale selon les zones géographiques. Un serveur central, géré par une entité neutre telle qu'un ministère de la santé ou une institution de recherche, est chargé de coordonner le processus d'agrégation des modèles.

Dans ce cadre, les acteurs du système sont au nombre de trois. Les institutions clientes, c'est-à-dire les hôpitaux participants, sont responsables de l'entraînement local du modèle et de la transmission sécurisée des paramètres mis à jour. Le serveur d'agrégation est responsable de combiner les contributions des clients pour produire un modèle global amélioré, sans jamais accéder aux données brutes. Enfin, les patients, bien qu'ils n'interagissent pas directement avec le système, en sont les bénéficiaires ultimes et leurs données en constituent la matière première, c'est pourquoi leur protection est au centre de toute la conception.

2.2 Exigences fonctionnelles

Les exigences fonctionnelles décrivent ce que le système doit être capable de faire. Elles ont été définies en s'appuyant à la fois sur les besoins identifiés dans le contexte d'utilisation et sur les enseignements tirés de l’état de l’art.

La première exigence fonctionnelle est la capacité d'entraînement local. Chaque nœud client doit pouvoir entraîner un modèle de classification sur ses données locales de manière autonome, sans dépendance permanente vis-à-vis du serveur central. Ce modèle local doit produire des paramètres, poids et gradients, exploitables pour l'agrégation globale.

La deuxième exigence est le chiffrement des paramètres avant transmission. Avant tout envoi vers le serveur d'agrégation, les paramètres du modèle local doivent être chiffrés à l'aide d'un schéma de chiffrement homomorphe. Ce chiffrement doit être réalisé localement, sans intervention du serveur, de sorte que même l'entité gestionnaire du serveur ne puisse pas accéder aux gradients individuels en clair.

La troisième exigence concerne l'agrégation homomorphe. Le serveur doit être capable d'agréger les contributions chiffrées de tous les clients participants pour produire un modèle global mis à jour, en opérant exclusivement sur des données

chiffrées. La fonction d'agrégation utilisée est une moyenne pondérée des paramètres, conforme à l'algorithme FedAvg.

La quatrième exigence est la redistribution du modèle global. Une fois l'agrégation effectuée, le serveur renvoie le résultat, toujours chiffré, à tous les hôpitaux. Chaque hôpital le déchiffre avec la clé secrète et obtient le nouveau modèle global. Ce modèle sert de point de départ pour le prochain cycle d'entraînement local.

La cinquième exigence est la capacité d'évaluation des performances. Le système doit permettre de mesurer, à chaque round d'entraînement, les métriques de performance du modèle global, précision, rappel, F1-score, ainsi que les métriques liées au chiffrement, temps de chiffrement et de déchiffrement, temps total par round, taille des messages échangés et mémoire vive (RAM) utilisée.

La sixième exigence, spécifique à ce mémoire, est la comparabilité des schémas de chiffrement. Le système doit permettre de basculer entre différents schémas homomorphes, CKKS, BFV et Paillier, sans modifier l'architecture globale, afin de permettre une comparaison empirique directe de leurs performances respectives dans un contexte médical.

2.3 Exigences non fonctionnelles

Les exigences non fonctionnelles définissent les qualités que le système doit posséder au-delà de ses fonctionnalités. Elles contraignent la manière dont le système accomplit ce qu'il fait.

La confidentialité est la première et la plus fondamentale de ces exigences. À aucun moment du processus d'entraînement, un participant y compris le serveur central, ne doit être en mesure d'accéder aux données brutes d'un autre participant. Cette propriété doit être garantie par construction, c'est-à-dire par le mécanisme cryptographique lui-même et non par une politique de confiance.

La robustesse aux attaques est étroitement liée à la précédente. Le système doit résister à l'inversion de gradients et aux attaques d'un serveur honnête-mais-curieux.

Il doit aussi réduire le risque d'inférence d'appartenance pendant l'entraînement, même si le chiffrement seul ne protège pas le modèle final (voir section 3.5). La résistance à ces attaques doit être vérifiable expérimentalement dans le cadre des expérimentations du Chapitre 5.

La performance acceptable est une exigence qui reconnaît le compromis inhérent à l'utilisation du chiffrement homomorphe. L'overhead computationnel introduit par le chiffrement ne doit pas rendre le système inutilisable en pratique. Un critère acceptable a été fixé : la dégradation de l'accuracy du modèle due au chiffrement ne doit pas dépasser 2 à 3 points de pourcentage par rapport au FL classique non chiffré, et le temps d'entraînement total ne doit pas être multiplié par plus de 10 sur les machines de test utilisées.

La modularité est une exigence technique importante pour la maintenabilité et l'évolutivité du prototype. Le code doit être structuré de manière à ce que le module de chiffrement, le module d'entraînement et le module d'agrégation soient clairement séparés et interchangeables. Cela facilite non seulement la comparaison des schémas HE mais aussi l'extension future du système.

La reproductibilité est une exigence propre au contexte académique. Toutes les expérimentations doivent être reproductibles par un tiers disposant du même code et des mêmes datasets. Les paramètres expérimentaux, seeds aléatoires, paramètres de chiffrement, hyperparamètres du modèle doivent être documentés de manière exhaustive.

2.4 Contraintes techniques et réglementaires

Le système conçu dans ce mémoire doit s'inscrire dans un ensemble de contraintes qui ne sont pas négociables et qui ont influencé les choix de conception.

Sur le plan technique, la contrainte principale est celle des ressources computationnelles. Le prototype doit pouvoir s'exécuter sur des machines ordinaires disposant de quelques gigaoctets de mémoire vive, sans nécessiter de matériel spécialisé ni d'infrastructure cloud. Cette contrainte est directement liée au contexte

africain : un système qui nécessiterait des serveurs GPU puissants pour fonctionner serait inapplicable dans la majorité des établissements de santé d'Afrique de l'Ouest dans l'état actuel de leurs infrastructures.

La contrainte de langage et d'outillage est également importante. Le prototype est développé en Python, qui est devenu le standard de facto pour les projets d'apprentissage automatique et dispose d'un écosystème de bibliothèques particulièrement riche. Deux bibliothèques sont utilisées pour le chiffrement. TenSEAL, construite sur Microsoft SEAL, gère les schémas CKKS et BFV et manipule facilement des vecteurs de poids. TenSEAL ne gère pas Paillier : la bibliothèque python-paillier (phe) est donc utilisée pour ce schéma. PyTorch est utilisé pour l'entraînement des modèles en raison de sa flexibilité et de la facilité avec laquelle il permet d'accéder aux gradients entre les rounds d'entraînement.

Pour les images de drépanocytose, nous utilisons un petit réseau déjà entraîné (MobileNet, disponible dans la bibliothèque torchvision). Ses couches sont figées, et seule la dernière couche est entraînée de façon fédérée. Le nombre de poids à chiffrer reste ainsi limité, ce qui permet de travailler sur une machine sans carte graphique.

Al-Janabi et al. (2025, p. 3094) utilisent une approche proche : ils combinent MobileNetV2, qui extrait les caractéristiques des images, avec un chiffrement CKKS pour classer des électrocardiogrammes.

Sur le plan réglementaire, bien que le prototype soit développé dans un cadre académique avec des données publiques, sa conception s'inspire des principes fondamentaux de protection des données personnelles. Le principe de minimisation des données, ne collecter et ne traiter que ce qui est strictement nécessaire et le principe de privacy by design, intégrer la protection de la vie privée dès la conception plutôt qu'après coup, guident les choix architecturaux. Ces principes sont consacrés par le RGPD européen et commencent à être repris dans les législations de protection des données personnelles de plusieurs pays africains, dont la loi sénégalaise sur les données personnelles administrée par la Commission de Protection des Données Personnelles.

2.5 Cas d'utilisation

Trois cas d'utilisation principaux structurent le fonctionnement du système. Ils décrivent les interactions entre les acteurs et le système dans des scénarios concrets.

Le premier cas d'utilisation est l'entraînement fédéré sécurisé. Dans ce scénario, plusieurs nœuds hospitaliers simulés (trois ou quatre selon le jeu de données) possèdent chacun une partie d'un jeu de données médical. Chaque nœud entraîne localement un modèle de classification pendant un nombre défini d'époques, puis chiffre ses paramètres avec le schéma choisi et les transmet au serveur. Le serveur additionne les paramètres chiffrés sans les déchiffrer, puis renvoie le résultat chiffré à tous les nœuds. Chaque nœud déchiffre ce résultat pour obtenir le modèle global. Ce cycle se répète pendant un nombre prédéfini de rounds. À l'issue de l'entraînement, le modèle global est évalué sur un jeu de test commun.

Le second cas d'utilisation est la comparaison des schémas de chiffrement. Le même protocole d'entraînement est exécuté quatre fois : d'abord sans chiffrement, puis avec CKKS, avec BFV et avec Paillier. Seul le schéma de chiffrement change d'une exécution à l'autre. Les métriques de performance et les temps d'exécution sont enregistrés pour chaque configuration. Ce cas d'utilisation produit les données nécessaires à l'analyse comparative du Chapitre 5.

Le troisième cas d'utilisation est la simulation d'attaque. Nous lançons d'abord une attaque par inversion de gradients sur l'apprentissage fédéré sans chiffrement. Le but est de montrer que l'attaquant peut retrouver une partie des données d'un patient. Nous relançons ensuite la même attaque quand les poids sont chiffrés. Le serveur ne voit alors que des messages chiffrés, et l'attaque ne peut plus aboutir. Ce cas d'utilisation démontre par l'expérience l'apport du chiffrement.

Ces trois cas d'utilisation sont formalisés sous forme de diagrammes UML présentés dans les figures suivantes. Le diagramme de cas d'utilisation global représente les interactions entre les acteurs et le système. Le diagramme de séquence détaille le

déroulement temporel d'un round d'entraînement fédéré sécurisé complet, de l'entraînement local au chiffrement jusqu'à la redistribution du modèle global.

Chapitre 3 : Conception d'un modèle théorique d'architecture sécurisée

Les deux premiers chapitres ont permis de comprendre pourquoi un système d'apprentissage fédéré classique ne suffit pas à protéger les données médicales, et ce que le système que nous concevons doit être capable de faire. Ce chapitre répond à une question différente et plus concrète : comment ce système va-t-il fonctionner ? Quels choix techniques sont retenus, et pourquoi ? Il ne s'agit pas encore de coder, mais de poser sur papier une architecture solide qui guidera toute l'implémentation du chapitre suivant.

3.1 Modèle de menace et hypothèses

Concevoir un système sécurisé sans définir précisément ce contre quoi on se protège serait une erreur méthodologique sérieuse. Avant de proposer une architecture, il faut répondre à trois questions essentielles : qui sont les adversaires potentiels, quelles actions peuvent-ils mener, et quelles hypothèses pose-t-on sur le comportement des acteurs du système ?

Dans le scénario considéré dans ce mémoire, trois types d'acteurs sont en jeu. Les nœuds clients représentent les hôpitaux participants. On suppose qu'ils suivent le protocole correctement, c'est-à-dire qu'ils entraînent leur modèle local honnêtement et transmettent leurs paramètres sans les manipuler. Cela dit, on ne suppose pas qu'ils se font mutuellement confiance : un hôpital de Thiès n'a aucune raison de vouloir exposer ses données patients à un hôpital de Saint-Louis, même dans le cadre d'un partenariat d'entraînement collaboratif.

Le serveur central est l'acteur qui mérite le plus d'attention dans le modèle de menace. On le qualifie d'honnête-mais-curieux, selon la terminologie consacrée dans la littérature cryptographique. Cela signifie qu'il exécute le protocole correctement, il agrège bien les gradients reçus et redistribue le modèle global, mais qu'il analyse également tout ce qu'il reçoit pour tenter d'en extraire des informations sur les données des participants. Cette hypothèse est particulièrement réaliste dans un contexte hospitalier ouest-africain où le serveur serait vraisemblablement géré par une institution tierce, comme un ministère de la santé ou une agence nationale, en qui les hôpitaux n'ont qu'une confiance partielle et institutionnelle.

Les adversaires externes sont des entités extérieures au système qui pourraient intercepter les communications entre les nœuds et le serveur. Leur objectif serait d'exploiter les gradients transmis pour tenter de reconstituer des données patients.

Face à ces acteurs, trois types d'attaques sont explicitement pris en compte dans la conception, en cohérence directe avec les vulnérabilités documentées dans la section 1.3 et confirmées expérimentalement par Hegde et al. (2025, p. 26023). L'attaque par inversion de gradients consiste à résoudre un problème d'optimisation inverse à partir des gradients observés pour reconstruire des données d'entraînement similaires. Sur des données médicales tabulaires comme la glycémie ou la pression artérielle, cette attaque peut révéler des informations cliniques sensibles sur des patients réels. L'attaque par inférence d'appartenance vise à déterminer si un enregistrement particulier a été utilisé pour entraîner le modèle. Même sans reconstruire les données complètes, cette information constitue à elle seule une violation de la vie privée dans un contexte médical. L'attaque d'un serveur honnête-mais-curieux consiste à analyser les gradients individuels reçus de chaque nœud pour inférer des informations sur les données locales, sans jamais sortir du cadre du protocole.

La conception repose sur cinq hypothèses qui délimitent le périmètre du système. On suppose d'abord que le canal de communication peut être intercepté et qu'on ne peut donc pas s'appuyer sur sa sécurité pour protéger les échanges. On suppose ensuite que le serveur ne possède pas la clé secrète. Il reçoit seulement la clé publique, qui lui

permet d’additionner des messages chiffrés sans pouvoir les lire. On suppose également que tous les hôpitaux partagent la même paire de clés. Un hôpital coordinateur crée cette paire, puis la transmet aux autres hôpitaux par un canal sécurisé. On suppose aussi que le serveur ne s’allie avec aucun hôpital. S’il le faisait, cet hôpital pourrait lui donner la clé secrète. Cette limite est connue dans la littérature et reste acceptable pour un prototype de cette taille. On suppose enfin que les données locales ne quittent jamais le nœud qui les détient, cette propriété étant garantie par la conception même du protocole FL horizontal.

3.2 Architecture globale proposée

L'architecture retenue est une architecture FL horizontale centralisée, composée de trois ou quatre nœuds clients simulant des hôpitaux, selon le jeu de données, et d'un serveur central d'agrégation.Ce choix s’inspire de la configuration de Hegde et al. (2025, p. 26021) et l'étend pour supporter la comparaison de plusieurs schémas de chiffrement dans un même cadre expérimental médical.

Le système repose sur quatre modules qui fonctionnent ensemble de manière séquentielle à chaque round d'entraînement. Le premier est le module d'entraînement local, qui réside chez chaque nœud client. Il charge la partition locale du dataset, entraîne le modèle pendant un nombre fixe d’époques (un petit réseau de neurones pour les données tabulaires, ou la dernière couche de MobileNet pour les images) et produit les paramètres mis à jour sous forme de tenseurs en virgule flottante. Ce module est identique chez tous les clients, la seule différence étant la partition de données sur laquelle il travaille.

Le deuxième est le module de chiffrement, également côté client. Il reçoit les paramètres produits par l'entraînement local, les aplatit en vecteurs unidimensionnels, et les chiffre à l'aide du schéma homomorphe retenu pour ce scénario expérimental. Ce module est conçu pour être interchangeable entre CKKS, BFV et Paillier sans que cela nécessite de modifier une autre partie du système. C'est cette modularité qui rend possible la comparaison empirique des trois schémas dans des conditions strictement identiques.

Le troisième est le module d'agrégation, qui réside sur le serveur.Il reçoit les messages chiffrés de tous les clients et les additionne directement, sans les déchiffrer. Il renvoie ensuite la somme chiffrée aux clients. Comme le serveur ne possède pas la clé secrète, il ne voit jamais aucun poids en clair, ni ceux d'un hôpital ni ceux du modèle global. C'est précisément là que réside la garantie de confidentialité vis-à-vis d'un serveur honnête-mais-curieux.

Le quatrième est le module d'évaluation. À chaque round, un hôpital déchiffre le modèle global et le teste sur un jeu de données commun, distinct des données d'entraînement de chaque client, pour mesurer l'accuracy, le rappel, le F1-score et les métriques temporelles liées au chiffrement. Ces mesures sont enregistrées systématiquement pour alimenter l'analyse comparative du Chapitre 5.

Le déroulement d'un round complet suit une séquence précise et répétée. Chaque nœud part du modèle global courant, qu'il a lui-même déchiffré à la fin du round précédent. Chaque nœud entraîne localement ce modèle sur ses propres données. Les paramètres mis à jour sont aplatis, chiffrés et transmis au serveur accompagnés du nombre d'exemples du nœud comme information de pondération. Le serveur additionne les contributions chiffrées de tous les clients et renvoie la somme chiffrée. Chaque client déchiffre cette somme et la divise par le nombre total d'exemples, ce qui donne le nouveau modèle global. Ce modèle est évalué sur le jeu de test commun, puis sert de point de départ pour le round suivant. Ce cycle se répète pendant dix rounds dans nos expérimentations, en cohérence avec Hegde et al. (2025, p. 26023), ce qui permettra une comparaison directe des résultats.

3.3 Choix et justification du schéma de chiffrement homomorphe

Le choix du schéma de chiffrement est une décision technique centrale qui a un impact direct sur la sécurité, la précision du modèle et les temps de calcul. Ce qui distingue ce mémoire des travaux existants est que ce choix n'est pas fait une fois pour toutes : trois schémas sont implémentés et comparés empiriquement dans le même cadre expérimental, sur les mêmes données, avec les mêmes métriques.

CKKS est inclus parce qu'il est conçu pour les nombres à virgule flottante, comme les poids d'un réseau de neurones. Parmi les trois schémas, c'est le seul qui les chiffre directement, sans conversion en entiers. En contrepartie, il produit une petite erreur d'arrondi. Hegde et al. ont testé CKKS sur des données médicales : le modèle fédéré chiffré atteint 98,6 % d'accuracy, contre 98,7 % sans chiffrement, soit une perte de 0,1 point (Hegde et al., 2025, p. 26023). Ce résultat porte toutefois sur des données en grande partie synthétiques. Pour le vérifier, ce mémoire teste aussi CKKS sur un jeu de données réel proche : Chronic Kidney Disease (UCI), qui porte sur la même maladie et contient 400 vrais patients indiens. Li et Li (2025, p. 4) indiquent de leur côté que CKKS est le deuxième schéma le plus utilisé en apprentissage fédéré, et qu'il est conçu pour calculer sur des nombres approchés.

Les paramètres cryptographiques retenus s'inspirent directement de ceux utilisés par Hegde et al. (2025, p. 26023, tableau IV) : un degré polynomial de 16 384, un module de coefficients de type [60, 40, 40, 60], une échelle de précision de 2^40 et un niveau de sécurité de 128 bits. Dans leur tableau, Hegde et al. indiquent un degré de « 16 834 ». Il s'agit très probablement d'une coquille, car le degré polynomial de CKKS doit être une puissance de 2, ici 16 384. Ces paramètres offrent un bon équilibre entre sécurité et performance sur des machines ordinaires sans carte graphique, ce qui est cohérent avec la contrainte de ressources limitées du contexte africain.

BFV est inclus dans la comparaison parce qu'il permet des calculs exacts sur des entiers, sans erreur d'arrondi. Comme CKKS, il peut regrouper des milliers de valeurs dans un seul message chiffré. Il reste pourtant très peu étudié en apprentissage fédéré : Li et Li (2025, p. 4, fig. 2) ne le trouvent que dans 3 % des études. Son inconvénient principal est qu'il travaille sur des entiers. Il faut donc convertir les poids, en les multipliant par un facteur d'échelle puis en les arrondissant. Cette conversion peut entraîner une perte de précision, dont l'effet sur un modèle médical sera mesuré au chapitre 5.

Paillier est inclus parce qu'il est le schéma le plus répandu en apprentissage fédéré. Li et Li (2025, p. 4, fig. 2) rapportent qu'il représente 36 % des études présentées dans

leur figure 2, ce qui en fait le schéma dominant entre 2021 et 2024. C'est également le schéma retenu par Shahid et al. (2026, p. 13) dans Health-FedNet. Sa popularité tient à sa simplicité et à sa rapidité sur les additions. On lui reproche souvent de ne pas permettre la multiplication entre messages chiffrés. Dans notre système, cette limite ne pose pas de problème : le serveur ne fait que des additions, puisqu'il calcule une moyenne. Paillier suffit donc pour cette tâche.Sa vraie faiblesse est ailleurs : dans sa version de base, celle de la bibliothèque phe, il chiffre une seule valeur à la fois. Zhang et al. (2020) montrent d'ailleurs qu'avec Paillier, le chiffrement occupe plus de 80 % du temps d'entraînement. Inclure Paillier dans la comparaison permettra de vérifier si sa popularité se traduit par de bonnes performances dans notre contexte.

3.3.1 Les vraies différences entre les trois schémas

Dans notre système, le serveur effectue seulement des additions. Les trois schémas peuvent donc tous réaliser l'agrégation. Leurs différences portent sur trois points. Le premier est le regroupement des valeurs : CKKS et BFV placent des milliers de poids dans un seul message chiffré, alors que Paillier, dans sa version de base, chiffre chaque poids séparément. Pour un modèle de 10 000 poids, il doit donc réaliser 10 000 chiffrements par round. Des versions de Paillier avec regroupement existent (Zhang et al., 2020), mais nous utilisons la version de base, celle de la bibliothèque phe. Ce choix sera discuté comme une limite au chapitre 6. Le deuxième est la précision : CKKS fait un calcul approché, tandis que BFV et Paillier exigent de convertir les poids en entiers, en les multipliant par un facteur fixe puis en les arrondissant. Le troisième est le coût : le temps de calcul, la taille des messages envoyés sur le réseau et la mémoire vive utilisée. Nos expériences mesurent ces trois points.

3.3.2 Un même niveau de sécurité pour les trois schémas

Pour que la comparaison soit juste, les trois schémas sont réglés au même niveau de sécurité de 128 bits. Pour CKKS, nous gardons les paramètres de Hegde et al. (degré 16 384). Pour BFV, nous utilisons un degré polynomial qui garantit aussi 128 bits.

Pour Paillier, la clé doit mesurer 3072 bits. En effet, une clé de 2048 bits, comme celle de Shahid et al. (2026, p. 13, tableau 7), n'offre qu'environ 112 bits de sécurité.

Ce choix a un coût. Zhang et al. (2020, p. 497, tableau 1) montrent que passer d'une clé de 2048 bits à une clé de 3072 bits multiplie le temps de chiffrement par environ 2,7 (de 1 153 s à 3 111 s pour 6,87 Mo de données). La taille des messages passe aussi de 527 Mo à 755 Mo.

3.4 Protocole d'apprentissage fédéré sécurisé

Ce protocole décrit les opérations réalisées à chaque round d'entraînement. Il est assez détaillé pour être codé directement au chapitre 4.

Avant le premier round, l'hôpital coordinateur crée une paire de clés selon le schéma choisi. Il transmet la clé secrète aux autres hôpitaux par un canal sécurisé. Le serveur reçoit seulement la clé publique : il peut additionner des messages chiffrés, mais il ne peut pas les lire. Un modèle initial avec des poids aléatoires est ensuite envoyé à tous les hôpitaux, pour que tous partent du même point. Une partie des données est mise de côté comme jeu de test commun et ne sert pas à l'entraînement. Le reste est réparti entre les hôpitaux. Pour Pima, Chronic Kidney Disease et la drépanocytose, les données sont découpées en trois parts. Pour UCI Heart Disease, chaque centre médical d'origine (Cleveland, Hongrie, Suisse, Long Beach) devient un hôpital.

Au début de chaque round, chaque hôpital part du modèle global courant. Il l'entraîne sur ses données locales pendant cinq époques, avec l'optimiseur Adam et un taux d'apprentissage de 0,001. L'optimiseur et le taux d'apprentissage reprennent ceux de Hegde et al. (2025, p. 26022). Hegde et al. utilisent aussi un arrêt anticipé avec une patience de 3 (p. 26022). Nous ne l'utilisons pas, afin que les quatre configurations comparées suivent exactement le même nombre d'époques. Le nombre de cinq époques a été choisi pour limiter le temps de calcul.

Après l'entraînement, chaque hôpital aplatit ses poids en un seul vecteur. Il multiplie ensuite ce vecteur par son nombre d'exemples (n□). Cette étape prépare la moyenne pondérée de l'algorithme FedAvg. Pour BFV et Paillier, l'hôpital convertit aussi les

poids en entiers. Il chiffre enfin le vecteur avec la clé publique et l'envoie au serveur, avec son nombre d'exemples.

Le serveur additionne les vecteurs chiffrés de tous les hôpitaux. Il obtient ainsi la somme chiffrée des poids pondérés. Il ne la déchiffre pas et la renvoie à tous les hôpitaux, avec le nombre total d'exemples (n).

Chaque hôpital déchiffre la somme avec la clé secrète. Il la divise par n, ce qui donne la moyenne pondérée, c'est-à-dire le nouveau modèle global. Pour BFV et Paillier, il reconvertit aussi les entiers en nombres décimaux. Le modèle est évalué sur le jeu de test commun, et les métriques du round sont enregistrées.

Ce protocole est répété pendant dix rounds, comme chez Hegde et al. (2025, p. 26023). Ce nombre permet d'observer la convergence du modèle avec des temps de calcul raisonnables.

3.5 Analyse théorique de sécurité

Cette section examine dans quelle mesure l'architecture proposée résiste aux trois types d'attaques identifiés dans le modèle de menace de la section 3.1.

Concernant l'attaque par inversion de gradients, la protection apportée par le chiffrement homomorphe est directe. Un adversaire qui intercepte les communications ne reçoit que des textes chiffrés. Sans la clé secrète, ces textes ne peuvent pas être déchiffrés, et encore moins exploités pour résoudre un problème d'optimisation inverse. Cette attaque repose fondamentalement sur la possibilité d'observer des valeurs numériques réelles et exploitables. Le chiffrement homomorphe transforme ces valeurs en données cryptographiquement opaques, rendant l'attaque sans objet. Hegde et al. ont vérifié cette protection par l'expérience : avec le chiffrement, les attaques sont devenues impossibles en pratique sur le plan du calcul (Hegde et al., 2025, p. 26024).

Concernant l'attaque par inférence d'appartenance, la protection n'est que partielle. Pendant l'entraînement, le serveur ne voit que des messages chiffrés et ne peut donc

pas les analyser. Cependant, à la fin, le modèle global est déchiffré et utilisé par les hôpitaux. Un attaquant qui accède à ce modèle final peut encore tenter cette attaque, et le chiffrement homomorphe ne protège pas contre ce risque. C'est pour cette raison que Shahid et al. (2026) ajoutent la confidentialité différentielle.Dans leur étude, le taux de succès de cette attaque passe de 43,2 % sans protection à 18,9 % avec la confidentialité différentielle seule, puis à 5,7 % avec la confidentialité différentielle et le chiffrement réunis (Shahid et al., 2026, p. 17, tableau 13). Leur étude d'ablation montre que l'ajout du chiffrement à la confidentialité différentielle fait passer la fuite de données de 9,8 % à 7,1 % (p. 19, tableau 17). Ce mémoire n'utilise pas la confidentialité différentielle, afin de mesurer l'effet du chiffrement seul. Cette limite sera discutée au chapitre 6.

Concernant l'attaque d'un serveur honnête-mais-curieux, la protection repose sur le fait que le serveur n'a jamais accès aux gradients individuels en clair. Il reçoit uniquement des textes chiffrés, effectue des additions sur ces messages et renvoie le résultat sans le déchiffrer. Comme il ne possède pas la clé secrète, il ne peut lire ni les poids d'un hôpital ni ceux du modèle global. Cette propriété est garantie par construction du protocole et non par une simple politique de confiance.

Une limite doit cependant être mentionnée. Dans ce protocole, tous les hôpitaux partagent la même clé secrète. Si le serveur s'allie avec un seul hôpital, il peut obtenir cette clé et lire les poids de tous les autres. Le système repose donc sur l'hypothèse que le serveur et les hôpitaux ne s'allient pas. Des solutions existent pour lever cette limite, comme le chiffrement à seuil (Jin et al., 2023, p. 3) ou le chiffrement multi-clés (Walskaar et al., 2023, p. 36). Dans ces approches, la clé secrète est répartie entre plusieurs acteurs, et aucun ne peut déchiffrer seul. Ces solutions constituent des pistes pour des travaux futurs.

Chapitre 4 : Implémentation du prototype

4.1 Implémentation expérimentale en Python (PyTorch)

4.2 Intégration d'une bibliothèque de chiffrement homomorphe

4.3 Implémentation du protocole fédéré

4.4 Interface et communication

4.5 Gestion des paramètres cryptographiques

Chapitre 5 : Expérimentations et résultats

5.1 Présentation des jeux de données

Les expériences utilisent quatre jeux de données médicaux publics, disponibles sur Kaggle et sur le dépôt UCI.

Le premier est Pima Indians Diabetes. Il contient 768 patientes âgées d'au moins 21 ans, d'origine Pima (Arizona, États-Unis). Chaque patiente est décrite par 8 variables cliniques, comme la glycémie, l'indice de masse corporelle, la pression artérielle et l'âge. La variable à prédire indique si la patiente est diabétique : 268 le sont (35 %) et 500 ne le sont pas. Certaines valeurs égales à zéro sont impossibles et correspondent en réalité à des données manquantes, par exemple 374 zéros pour l'insuline. Elles sont traitées avant l'entraînement.

Le deuxième est UCI Heart Disease. Il regroupe environ 920 patients venant de quatre centres médicaux : Cleveland, la Hongrie, la Suisse et Long Beach. Chaque centre joue le rôle d'un hôpital dans notre système. Ce découpage est réaliste, car les patients et la qualité des données varient d'un centre à l'autre.

Le troisième jeu porte sur la drépanocytose. Il contient des images de frottis sanguins prises au microscope en Ouganda, dans les districts de Soroti et de Kumi : 147 images

négatives et 422 images positives (Tushabe et al., 2024, p. 22). Les échantillons de sang proviennent de 140 personnes : 105 personnes drépanocytaires et 35 personnes non drépanocytaires (p. 23). Les photos ont été prises avec des téléphones portables placés sur l'oculaire du microscope (p. 23), ce qui correspond bien aux moyens disponibles dans les hôpitaux africains. Les lames ont été colorées selon deux méthodes : la coloration de Field, qui donne une teinte violette, et celle de Leishman, qui donne une teinte rose (p. 26). Les deux classes ne sont cependant pas équilibrées sur ce point : 57 % des images positives sont colorées au Leishman, contre seulement 38 % des images négatives (p. 25). Un modèle pourrait donc apprendre à reconnaître la couleur plutôt que la maladie. Pour contrôler ce risque, nous mesurerons aussi les résultats séparément pour chaque type de coloration.

Chaque image positive existe aussi en version annotée, avec des cadres autour des cellules en forme de faucille (p. 26). Nous utilisons seulement les versions sans cadre, pour éviter les doublons et pour que le modèle n'apprenne pas à reconnaître les cadres. Toutes les images sont ramenées à la même taille. Ce jeu permet de tester le système sur des images, et sur une maladie très fréquente en Afrique subsaharienne.

Chaque image positive existe aussi en version annotée, avec des cadres autour des cellules en forme de faucille. Nous utilisons seulement les versions sans cadre, pour éviter les doublons et pour que le modèle n'apprenne pas à reconnaître les cadres. Toutes les images sont ramenées à la même taille. Ce jeu permet de tester le système sur des images, et sur une maladie très fréquente en Afrique subsaharienne.

Le quatrième est Chronic Kidney Disease (UCI). Il contient 400 patients de l'hôpital Apollo de Karaikudi, en Inde, décrits par 24 variables cliniques. Il est proche de celui de Hegde et al. (2025), qui étudient la même maladie avec 399 patients d'un hôpital de Bangalore et 17 variables (p. 26020). Les deux jeux restent cependant différents : celui de Hegde et al. sert à prédire le stade de la maladie, de 1 à 5, alors que le nôtre indique seulement si le patient est malade ou non. La comparaison avec Hegde et al. sera donc seulement indicative. De plus, ce jeu est très facile à classer : un modèle simple atteint presque 100 % de bonnes réponses. Il ne sert donc pas à comparer la

précision des schémas, mais plutôt leurs temps de calcul et la taille des messages sur un petit modèle.

Deux autres jeux téléchargés au départ ont été écartés. Le premier, un jeu de 10 000 patients sur les maladies cardiaques, ne permet aucune prédiction : un modèle n'y fait pas mieux que le hasard (AUC de 0,50). Le second, « Federated Health Records », ne contient aucun patient malade, car ses 1 000 lignes portent toutes la même étiquette. Ces vérifications montrent l'importance de contrôler la qualité des données avant toute expérience.

5.2 Protocole expérimental

5.3 Métriques d'évaluation

5.4 Résultats de performance des modèles

5.5 Impact du chiffrement sur les temps de calcul

5.6 Analyse comparative : FL classique et FL chiffré (CKKS, BFV, Paillier)

Chapitre 6 : Discussion et perspectives

6.1 Synthèse des contributions

6.2 Limitations de l'approche

6.3 Implications pratiques

6.4 Travaux futurs

Conclusion et perspectives

Synthèse des travaux réalisés

Apports du projet

Perspectives d'amélioration

Références bibliographiques

Al-Janabi, A. A., Al-Janabi, S., & Al-Khateeb, B. (2025). Towards efficient and privacy preserving ECG classification: Federated transfer learning enhanced by CKKS-based homomorphic encryption. *Baghdad Science Journal*, 22(9),3094–3113. https://doi.org/10.21123/2411-7986.5066 .

Benaissa, A., Retiat, B., Cebere, B., & Belfedhal, A. E. (2021). TenSEAL: A library for encrypted tensor operations using homomorphic encryption. *arXiv:2104.03152*.

Brakerski, Z. (2012). Fully homomorphic encryption without modulus switching from classical GapSVP. In *Advances in Cryptology – CRYPTO 2012* (LNCS 7417, pp. 868–886). Springer.

Cheon, J. H., Kim, A., Kim, M., & Song, Y. (2017). Homomorphic encryption for arithmetic of approximate numbers. In *Advances in Cryptology – ASIACRYPT 2017* (LNCS 10624, pp. 409–437). Springer.

CSIRO's Data61. (2013). *Python Paillier library (phe)*. https://github.com/data61/python-paillier

Fabila, J., Campello, V. M., Martín-Isla, C., Obungoloch, J., Leo, K., Ronald, A., & Lekadir, K. (2024). Democratizing AI in Africa: Federated learning for low-resource edge devices. *arXiv:2408.17216*.

Fan, J., & Vercauteren, F. (2012). Somewhat practical fully homomorphic encryption. *IACR Cryptology ePrint Archive*, 2012/144.

Gentry, C. (2009). Fully homomorphic encryption using ideal lattices. In *Proceedings of the 41st ACM Symposium on Theory of Computing (STOC)* (pp. 169–178).

Hegde, M. G., Ruthvika, B., Jain, R. B., Shenoy, P. D., Venugopal, K. R., & Canchi, A. (2025). A privacy-preserving federated learning method with homomorphic encryption for chronic kidney disease stage prediction. *Engineering, Technology & Applied Science Research*, 15(4), 26019–26026. https://doi.org/10.48084/etasr.11928

Howard, A. G., et al. (2017). MobileNets: Efficient convolutional neural networks for mobile vision applications. *arXiv:1704.04861*.

Janosi, A., Steinbrunn, W., Pfisterer, M., & Detrano, R. (1988). *Heart Disease* [Jeu de données]. UCI Machine Learning Repository.

Jiang, Z., Wang, W., & Liu, Y. (2021). FLASHE: Additively symmetric homomorphic encryption for cross-silo federated learning. *arXiv:2109.00675*.

Jin, W., Yao, Y., Han, S., Gu, J., Joe-Wong, C., Ravi, S., Avestimehr, S., & He, C. (2023). FedML-HE: An efficient homomorphic-encryption-based privacy-preserving federated learning system. *arXiv:2303.10837*.

Jorge, H., Wanzeller, C., & Henriques, J. (2025). Evaluating homomorphic encryption schemes for privacy and security in healthcare data management. *Journal of Cybersecurity and Privacy*, 5(3), 74.**https://doi.org/10.3390/jcp5030074**

Karimireddy, S. P., Kale, S., Mohri, M., Reddi, S., Stich, S., & Suresh, A. T. (2020). SCAFFOLD: Stochastic controlled averaging for federated learning. In *Proceedings of ICML 2020* (PMLR 119, pp. 5132–5143).

Korkmaz, A., & Rao, P. (2025). A selective homomorphic encryption approach for faster privacy-preserving federated learning. *arXiv:2501.12911*.

Li, H., & Li, Z. (2025). Homomorphic encryption in federated learning: A systematic review of current methods and open challenges. *SSRN 5358246* (prépublication).

Li, T., Sahu, A. K., Zaheer, M., Sanjabi, M., Talwalkar, A., & Smith, V. (2020). Federated optimization in heterogeneous networks. *Proceedings of Machine Learning and Systems*, 2, 429–450.

McMahan, B., Moore, E., Ramage, D., Hampson, S., & Agüera y Arcas, B. (2017). Communication-efficient learning of deep networks from decentralized data. In *Proceedings of AISTATS 2017* (PMLR 54, pp. 1273–1282).

Paillier, P. (1999). Public-key cryptosystems based on composite degree residuosity classes. In *Advances in Cryptology – EUROCRYPT '99* (LNCS 1592, pp. 223–238). Springer.

Rivest, R. L., Adleman, L., & Dertouzos, M. L. (1978). On data banks and privacy homomorphisms. *Foundations of Secure Computation*, 4(11), 169–180.

Rubini, L., Soundarapandian, P., & Eswaran, P. (2015). *Chronic Kidney Disease* [Jeu de données]. UCI Machine Learning Repository.

Shahid, M. I., Badar, H. M. S., Asghar, M. N., & Abdullah, A. (2026). Health-FedNet: Secure federated learning for chronic disease prediction on MIMIC-III with differential privacy and homomorphic encryption. *Scientific Reports*, 16, 7968. https://doi.org/10.1038/s41598-026-36034-y

Smith, J. W., Everhart, J. E., Dickson, W. C., Knowler, W. C., & Johannes, R. S. (1988). Using the ADAP learning algorithm to forecast the onset of diabetes mellitus. In *Proceedings of the Annual Symposium on Computer Application in Medical Care* (pp. 261–265).

Tushabe, F., Mwesige, S., Vicent, K., Othieno, E., Nsiimire, E., Mutabazi, P., Musani, S., & Areu, D. (2024). A dataset of microscopic images of sickle and normal red blood cells. *Acta Scientific Microbiology*, 7(12), 22–29. https://doi.org/10.31080/ASMI.2024.07.1453

Walskaar, I., Tran, M. C., & Catak, F. O. (2023). A practical implementation of medical privacy-preserving federated learning using multi-key homomorphic encryption and Flower framework. *Cryptography*, 7(4), 48. https://doi.org/10.3390/cryptography7040048

Zhang, C., Li, S., Xia, J., Wang, W., Yan, F., & Liu, Y. (2020). BatchCrypt: Efficient homomorphic encryption for cross-silo federated learning. In *Proceedings of USENIX ATC 2020* (pp. 493–506).

Zhu, L., Liu, Z., & Han, S. (2019). Deep leakage from gradients. In *Advances in Neural Information Processing Systems 32 (NeurIPS 2019)*.

Règlement (UE) 2016/679 du Parlement européen et du Conseil du 27 avril 2016 (Règlement général sur la protection des données).

Loi n° 2008-12 du 25 janvier 2008 sur la protection des données à caractère personnel (Sénégal).

Annexes

Annexe A : Détails des paramètres expérimentaux

Annexe B : Extraits de code

Annexe C : Glossaire des termes techniques

Annexe D : Publications et communications